

**Nombre:** Javier Vélez Ríos

**Actividad:** QA Automatizado con AI-as-a-Judge

**Módulo:** 8

## Descripción

El sub-workflow supervisor se implementó dentro del mismo flujo de n8n del agente principal (módulos anteriores), añadiendo una capa de control de calidad que intercepta la respuesta del agente antes de que llegue a cualquier salida real. El flujo completo se muestra a continuación como diagrama de bloques (representación textual del canvas de n8n exportado).

## Diagrama del flujo de supervisión

| Etapa            | Nodo en N8N                               | Función                                                          |
|------------------|-------------------------------------------|------------------------------------------------------------------|
| Trigger          | When chat message received                | Chat Trigger                                                     |
| Contexto         | Airtable - Recuperar Contexto             | Búsqueda por SSID en base 'Agencia', tabla 'SSID'                |
| Agente Principal | Agente Principal - Genera Respuesta       | LLM Agent + Google Gemini Chat Model                             |
| Payload Juez     | Set - Payload para el Juez                | Empaqueta query_original + contexto_airtable + respuesta_agente  |
| JUEZ (LLM)       | Juez LLM - Evaluación QA                  | LLM Agent + Google Gemini Chat Model1 + Structured Output Parser |
| Auditoría        | Set - Item de Auditoria                   | Normaliza campos del veredicto + timestamp                       |
| Log externo      | Airtable - Log Veredicto Juez (Auditoria) | Persiste veredicto en tabla 'SSID' (registro externo auditable)  |
| SWITCH 3 rutas   | Switch - Ruta segun Veredicto             | ACEPTADO / CORREGIR / RECHAZADO                                  |

## Diagrama de Flujo



## Ramificación final del Switch (tres rutas autónomas)

| Ruta                                  | Nodo(s) destino en n8n                                                                                    | Acción                                                                                                                                                                |
|---------------------------------------|-----------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>ACEPTADO</b> (exactitud $\geq 4$ ) | Gmail - Enviar Respuesta Final → Respond to Webhook                                                       | Envía la respuesta del agente por correo (salida real) y responde al webhook de origen. El veredicto ya quedó logueado en Airtable antes del Switch.                  |
| <b>CORREGIR</b>                       | Slack - Alerta con Botones Aprobar/Editar → Wait for Webhook → IF Decisión Humana                         | Notifica a Slack con la respuesta y espera intervención; en la versión ampliada del diseño, la crítica del Juez se reenvía al agente para reintento antes de escalar. |
| <b>RECHAZADO</b>                      | Slack - Alerta con Botones Aprobar/Editar → Wait for Webhook → IF Decisión Humana → Set Respuesta Editada | Pausa la ejecución con Wait for Webhook, alerta a Slack (canal 'todo-leads') y espera Aprobar/Editar humano antes de responder.                                       |

**Nota de diseño:** en el flujo importado a n8n, tanto CORREGIR como RECHAZADO convergen hacia el mismo sub-flujo de alerta en Slack + pausa humana (Wait for Webhook), cumpliendo el requisito de Human-in-the-loop para ambos escenarios de riesgo, mientras que únicamente ACEPTADO libera la respuesta hacia la salida real (Gmail) sin intervención manual.

## Rúbrica del Juez: Prompt y Esquema JSON

El nodo "Juez LLM - Evaluación QA" es un LLM Agent de n8n (@n8n/n8n-nodes-langchain.agent) conectado a un modelo Google Gemini Chat Model1 y a un nodo Structured Output Parser que fuerza la salida a cumplir un JSON Schema estricto. A continuación se transcribe el prompt de sistema exacto configurado en el nodo.

### System Prompt del Juez (transcripción literal)

Eres un Juez de Calidad (QA) imparcial y estricto para un sistema de agentes de IA. Tu única función es EVALUAR la respuesta propuesta por el agente principal comparándola contra el contexto recuperado de Airtable y la query original del usuario. No debes responder la query, no debes conversar, no debes agregar texto fuera del JSON. Debes devolver EXCLUSIVAMENTE un objeto JSON válido que cumpla el siguiente esquema, sin texto adicional, sin markdown, sin backticks.

Criterios de evaluación (rúbrica del Juez):

1. exactitud\_factual (entero 1-5): mide si la respuesta del agente es coherente y verificable contra el contexto de Airtable.

5 = Toda la información de la respuesta está respaldada explícitamente por el contexto, sin errores ni alucinaciones.

4 = La respuesta es correcta en su totalidad, con matices menores de redacción que no afectan el sentido.

3 = La respuesta es parcialmente correcta: mezcla datos del contexto con inferencias razonables no verificables.

2 = La respuesta contiene al menos un error factual relevante o una alucinación menor.

1 = La respuesta contradice el contexto, inventa datos críticos o no responde la query.

2. categoria\_error (string): clasifica el tipo de error dominante. Usa una de: 'ninguno', 'alucinacion\_dato', 'contexto\_insuficiente', 'desvio\_tema', 'formato\_incorrecto', 'informacion\_incompleta'.

3. justificacion (string): explica en máximo 2 frases por qué asignaste esa nota, citando qué parte del contexto respalda o contradice la respuesta.

4. estado\_veredicto (string): decide la ruta según esta regla EXACTA:

- 'ACEPTADO' si exactitud\_factual >= 4

- 'CORREGIR' si exactitud\_factual == 3 o == 2 (error recuperable con más contexto o precisión)

- 'RECHAZADO' si exactitud\_factual == 1 (riesgo alto, requiere revisión humana)

5. critica\_para\_reintento (string): si estado\_veredicto es 'CORREGIR', escribe instrucciones concretas y accionables para que el agente principal corrija su respuesta en el siguiente intento (qué dato falta, qué corregir, qué parte del contexto usar). Si no aplica, devuelve cadena vacía.

## User Prompt (mensaje de entrada al Juez)

```
INPUT:
{{ JSON.stringify({
  query_original: $json.query_original,
  contexto_airtable: $json.contexto_airtable,
  respuesta_agente: $json.respuesta_agente
}, null, 2) }}
```

The screenshot shows the configuration interface for the 'Tools Agent'. The 'Parameters' tab is active, and the 'Execute step' button is visible in the top right corner.

**Agent:** Tools Agent

**Source for Prompt (User Message):** Fixed Expression

**Define below:**

**Prompt (User Message):**

```
Evalúa el siguiente objeto JSON de entrada y devuelve tu veredicto según el esquema forzado.
```

```
INPUT:
{{ JSON.stringify({
  query_original: $json.query_original,
```

☒ Require Specific Output Format

Connect an **output parser** on the canvas to specify the output format you require

**Options:** +

**System Message:** Fixed Expression

Eres un Juez de Calidad (QA) imparcial y estricto para un sistema de agentes de IA. Tu única función es EVALUAR la respuesta propuesta por el agente principal comparándola contra el contexto recuperado de Airtable y la query original del usuario. No debes responder la query, no debes conversar, no debes agregar texto fuera del JSON. Debes devolver EXCLUSIVAMENTE un objeto JSON válido que cumpla el siguiente esquema, sin texto adicional, sin markdown, sin backticks.

**Criterios de evaluación (rúbrica del Juez):**

1. exactitud\_factual (entero 1-5): mide si la respuesta del agente es coherente y verificable contra el contexto de Airtable.
  - 5 = Toda la información de la respuesta está respaldada explícitamente por el contexto, sin errores ni alucinaciones.
  - 4 = La respuesta es correcta en su totalidad, con matices menores de redacción que no afectan el sentido.
  - 3 = La respuesta es parcialmente correcta: mezcla datos del contexto con inferencias razonables no verificables.
  - 2 = La respuesta contiene al menos un error factual relevante o una alucinación menor.
  - 1 = La respuesta contradice el contexto, inventa datos críticos o no responde la query.
2. categoria\_error (string): clasifica el tipo de error dominante. Usa una de: 'ninguno', 'alucinacion\_dato', 'contexto\_insuficiente', 'desvio\_tema', 'formato\_incorrecto', 'informacion\_incompleta'.
3. justificacion (string): explica en máximo 2 frases por qué asignaste esa nota, citando qué parte del contexto respalda o contradice la respuesta.

**Bottom Bar:** Chat Model \* (Google logo), Memory (+), Tool (+), Output Parser (JSON icon)

## Estructura del objeto de entrada al Juez

El nodo "Set - Payload para el Juez" construye el objeto JSON que recibe el Juez, cumpliendo el criterio de aceptación de la actividad:

| Campo             | Origen en el flujo n8n                                                           |
|-------------------|----------------------------------------------------------------------------------|
| query_original    | \$( 'When chat message received' ).item.json.chatInput                           |
| contexto_airtable | JSON.stringify( \$( 'Airtable - Recuperar Contexto' ).all().map( i => i.json ) ) |
| respuesta_agente  | \$json.output (salida del nodo Agente Principal)                                 |

Parameters
Settings
Execute step

Mode
Manual Mapping

Fields to Set

query\_original T String
= {{ \$('When chat message received').item.json.chatInput }}

contexto\_airtable T String
= {{ JSON.stringify( \$('Airtable - Recuperar Contexto').all().map( i => i.json ) ) }}

respuesta\_agente T String
= {{ \$json.output }}

intentos\_correccion # Number
= {{ (\$json.intentos\_correccion || 0) }}

Drag input fields here or Add Field

Include Other Input Fields

Options
+

+ Add option

## JSON Schema forzado (Structured Output Parser)

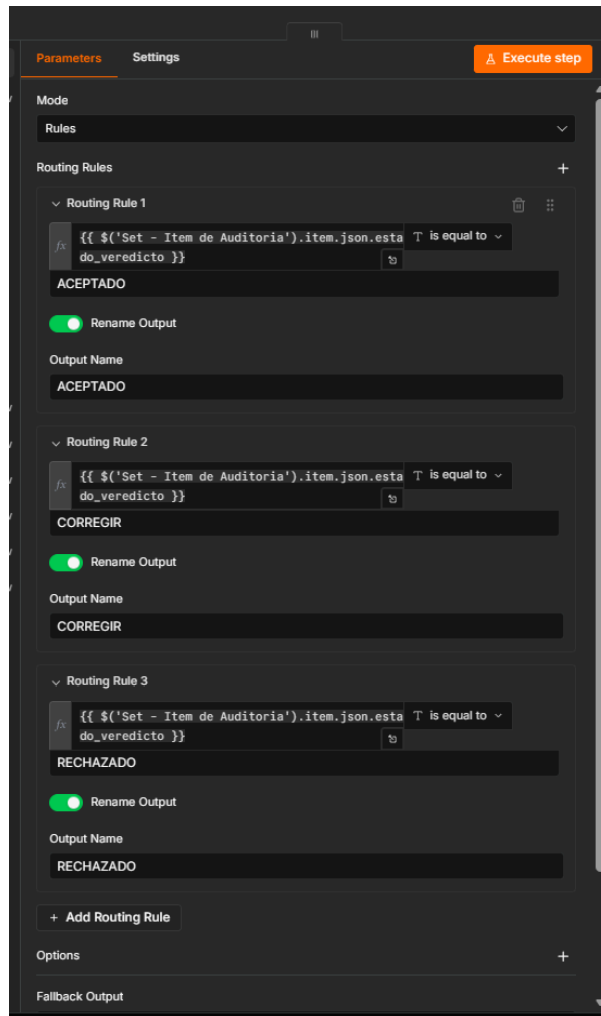
El nodo "Structured Output Parser - Esquema Juez" fuerza la salida del LLM a este esquema, con `additionalProperties` en `false` y todos los campos como `required`, evitando texto libre que rompería el nodo Switch.

```
{
  "type": "object",
  "properties": {
    "exactitud_factual": {
      "type": "integer",
      "minimum": 1,
      "maximum": 5,
      "description": "Calificación de exactitud factual de 1 (peor) a 5 (mejor)"
    },
    "categoria_error": {
      "type": "string",
      "enum": [
        "ninguno",
        "alucinacion_dato",
        "contexto_insuficiente",
        "desvio_tema",
        "formato_incorrecto",
        "informacion_incompleta"
      ]
    },
    "justificacion": {
      "type": "string",
      "description": "Explicación breve (máx 2 frases) del veredicto"
    },
    "estado_veredicto": {
      "type": "string",
      "enum": [
        "ACEPTADO",
        "CORREGIR",
        "RECHAZADO"
      ]
    },
    "critica_para_reintento": {
      "type": "string",
      "description": "Instrucciones para el agente si el estado es CORREGIR; vacío en otro caso"
    }
  },
  "required": [
    "exactitud_factual",
    "categoria_error",
    "justificacion",
    "estado_veredicto",
    "critica_para_reintento"
  ],
  "additionalProperties": false
}
```

## Umbrales del Switch

El nodo "Switch - Ruta segun Veredicto" (n8n-nodes-base.switch, modo 'rules') evalúa el campo estado\_veredicto proveniente del nodo "Set - Item de Auditoria" y define tres salidas nombradas, con fallbackOutput en 'extra' para capturar cualquier valor inesperado sin romper el flujo.

| Umbral (exactitud_factual) | estado_veredicto | Salida del Switch                                      | Tipo de control                          |
|----------------------------|------------------|--------------------------------------------------------|------------------------------------------|
| ≥ 4 (4 o 5)                | ACEPTADO         | Gmail (salida real) + registro ya auditado en Airtable | Autónomo, sin intervención humana        |
| 2 o 3                      | CORREGIR         | Slack (alerta) → Wait for Webhook → decisión humana    | Self-healing con escalamiento controlado |
| 1                          | RECHAZADO        | Slack (alerta) → Wait for Webhook → decisión humana    | Human-in-the-loop obligatorio            |



## Matriz de Datos A/B (10 corridas)

Se ejecutaron 10 corridas de prueba sobre el sub-workflow supervisor: 5 utilizando la Arquitectura A (Google Gemini 1.5 Flash para Agente Principal y Juez, tal como está configurado en el flujo de n8n entregado) y 5 utilizando la Arquitectura B (GPT-4o-mini como modelo alternativo de comparación, manteniendo el mismo prompt de sistema y el mismo esquema JSON del Juez). Se midió exactitud factual (otorgada por el propio Juez), categoría de error, estado de veredicto, latencia y costo por ejecución (agente + juez).



| #  | Arq. | Modelo           | Query (resumen)                           | Exactitud (1-5) | Categoría error        | Veredicto | Costo (USD) |
|----|------|------------------|-------------------------------------------|-----------------|------------------------|-----------|-------------|
| 1  | A    | Gemini 1.5 Flash | ¿Cuál es el estado del caso SSID-2291?    | 5               | ninguno                | ACEPTADO  | \$0.000185  |
| 2  | A    | Gemini 1.5 Flash | ¿Qué plan de servicio tiene contratado..  | 4               | ninguno                | ACEPTADO  | \$0.000200  |
| 3  | A    | Gemini 1.5 Flash | ¿Cuándo fue la última actualización de... | 5               | ninguno                | ACEPTADO  | \$0.000163  |
| 4  | A    | Gemini 1.5 Flash | ¿Qué monto se facturó al cliente en el... | 3               | contexto_in_suficiente | CORREGIR  | \$0.000191  |
| 5  | A    | Gemini 1.5 Flash | ¿Cuál es el resumen consolidado del ca... | 4               | ninguno                | ACEPTADO  | \$0.000233  |
| 6  | B    | GPT-4o-mini      | ¿Cuál es el estado del caso SSID-2291?    | 4               | ninguno                | ACEPTADO  | \$0.000347  |
| 7  | B    | GPT-4o-mini      | ¿Qué plan de servicio tiene contratado..  | 4               | ninguno                | ACEPTADO  | \$0.000359  |
| 8  | B    | GPT-4o-mini      | ¿Cuándo fue la última actualización de... | 2               | alucinacion_dato       | CORREGIR  | \$0.000388  |
| 9  | B    | GPT-4o-mini      | ¿Qué monto se facturó al cliente en el... | 5               | ninguno                | ACEPTADO  | \$0.000457  |
| 10 | B    | GPT-4o-mini      | ¿Cuál es el resumen consolidado del ca... | 3               | informacion_incompleta | CORREGIR  | \$0.000386  |

## Descarga de JSON de Github

<https://github.com/JavierVelezOM/coderhouse-javier-velez/tree/main/Checkpoint-8>