DOCUMENTACIÓN MAESTRA DEL SISTEMA AGÉNTICO

Sistema Agéntico Empresarial Supervisado para Automatización de Ventas y Atención al Cliente

Caso: Viajes Laguna (México - Sudamérica - Europa)

Datos del Proyecto

- **Título del Proyecto:** Despliegue y Gobernanza de un Ecosistema Agéntico Asincrónico y Supervisado para Viajes Laguna.
- **Autor / Consultor:** Javier Vélez Ríos.
- **Programa:** Certificación en AI Automation Avanzado - Módulo 11: Proyecto Final Integrador.
- **Institución:** Coderhouse.
- **Cohorte:** 2026.
- **Pila Tecnológica:** n8n v2.21.4 (Self-Hosted), Google Gemini 3.5 Flash, Google Drive API, Google Sheets API, Airtable REST API, Slack API, Gmail API (100% Freemium / Free-tier).

Proyecto completo en GIT Hub

https://github.com/JavierVelezOM/coderhouse-javier-velez/edit/main/velez_javier_proyecto_final_ai_experto/

Video demostrativo

https://youtu.be/IDncoMTL-sY

Resumen Ejecutivo

Viajes Laguna es una agencia de viajes mexicana especializada en itinerarios internacionales hacia Sudamérica y Europa. Previo a la implementación de esta solución agéntica, la empresa experimentaba una severa fricción operativa caracterizada por:

1. **Lead Time Comercial Elevado:** El tiempo promedio de respuesta y cotización personalizada oscilaba entre 12 y 18 horas hábiles, provocando una fuga de prospectos calificados hacia competidores directos.
2. **Riesgo Legal y Financiero por Alucinaciones Humanas:** Asesores comerciales novatos cometían inconsistencias frecuentes al citar políticas de penalización y reembolsos por cancelación, ocasionando disputas contractuales y pérdidas directas de hasta $15,000 USD anuales en devoluciones indebidas.
3. **Sobrecarga Administrativa:** Más del 65% del tiempo de la fuerza de ventas se consumía en responder consultas repetitivas de normativas, visados y tarifas base en lugar de cerrar negociaciones de alto valor.

Solución Implementada

Se diseñó y desplegó un ecosistema operativo agéntico asincrónico, modular e idempotente bajo el patrón Manager-Worker. El sistema atiende interacciones vía chat en tiempo real, consulta dinámicamente un repositorio RAG dual (catálogo de tarifas en Google Sheets y manual de políticas en Google Docs), y somete cada respuesta a una compuerta estricta de control de calidad mediante un supervisor independiente 'AI-as-a-Judge'. Las cotizaciones validadas se despachan instantáneamente al canal de ventas en Slack y se consolidan en el CRM Airtable, mientras que cualquier inconsistencia factual o riesgo de alucinación congela automáticamente la autonomía y deriva el caso a una cola de revisión humana (HITL), garantizando cero margen de error en producción.

SECCIÓN 2: DIAGRAMA DE ARQUITECTURA DE n8n Y GOBERNANZA TÉCNICA

Principios de Diseño

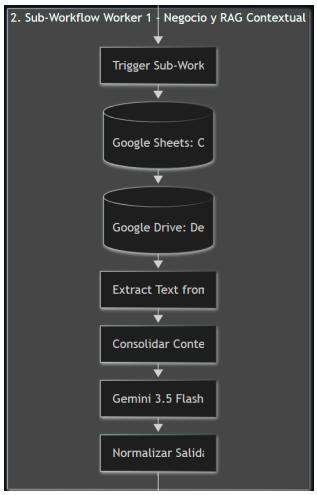
El sistema rechaza arquitecturas monolíticas y se estructura en tres flujos desacoplados bajo el estándar Manager-Worker:

1. **Flujo Manager (Orquestador de Entrada & Idempotencia):** Captura el estímulo mediante Chat Trigger, extrae y normaliza el identificador de sesión (SSID) y correo electrónico, genera un TraceID único (`VL-TRC-...`) para trazabilidad transversal y consulta la base de datos persistente en Airtable.
2. **Sub-workflow Worker 1 (Negocio & RAG Contextual):** Realiza la ingesta documental en serie del Google Sheet de destinos/precios y del manual de políticas en Google Docs, suministrando a Google Gemini 3.5 Flash directrices strictly de contención: prohibición de invención, cita obligatoria de fuentes con metadatos y declaración explícita de 'No sé' ante datos no indexados.
3. **Sub-workflow Worker 2 (Supervisor AI-as-a-Judge & Calidad Activa):** Actúa como juez ciego evaluando la propuesta del Worker 1 frente a la consulta original bajo una rúbrica JSON Schema. Aplica una compuerta de calidad ('Quality Gate'): si la exactitud factual es menor a 4, congela la autonomía, alerta al equipo en Slack (#cola-aprobacion-hitl) y genera un reporte por Gmail; si la exactitud es mayor o igual a 4 y detecta intención de cotización, despacha el prospecto al equipo de ventas (#ventas-laguna) y consolida el lead en Airtable.

Diagrama de Flujos







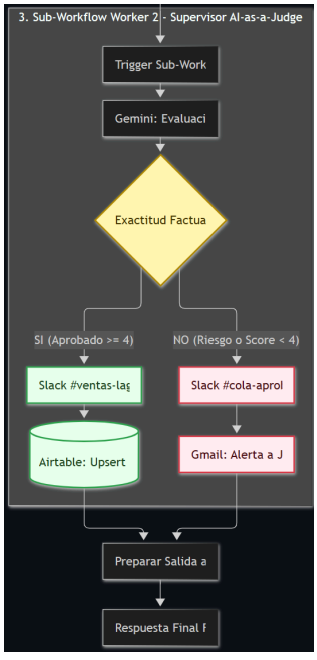


Diagrama de arquitectura en n8n

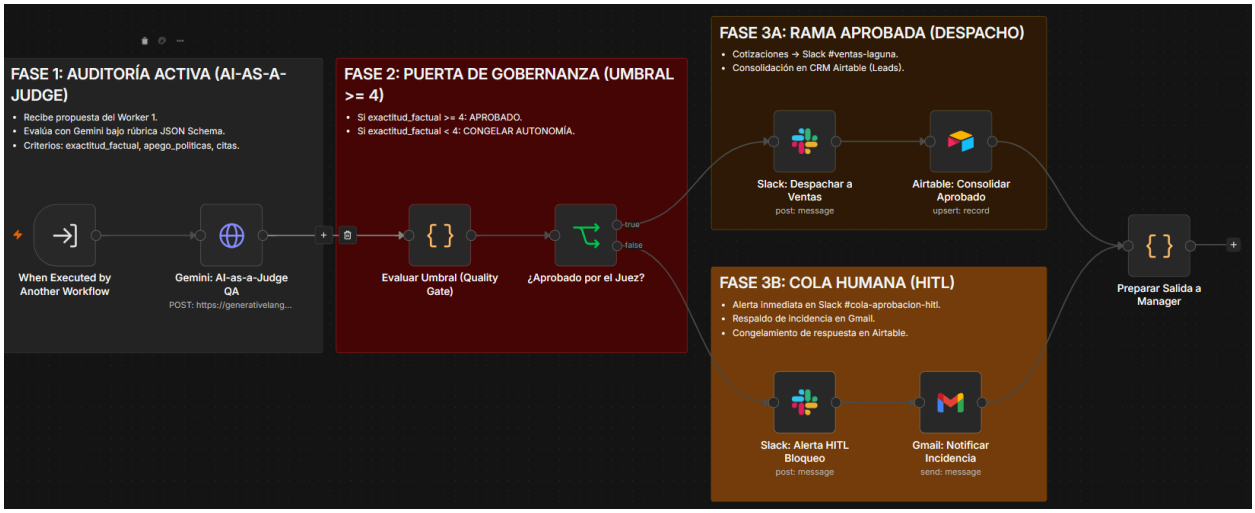
Main Worker



SubWorker__Negocio__RAG__Destinos__Politicas



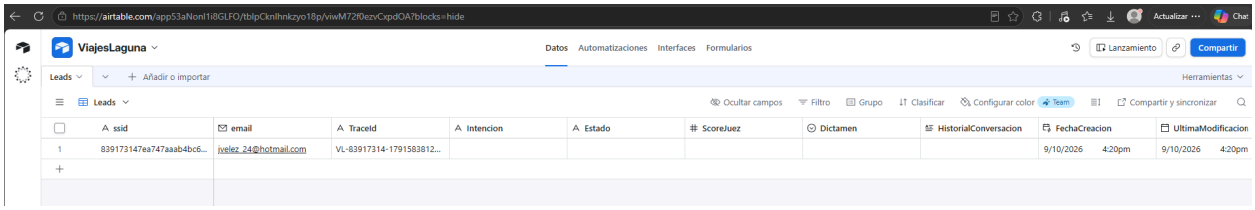
SubWorker__Negocio__RAG_ Destinos __ Políticas



Memoria Persistente y Correlación (Airtable Leads)

La base de datos relacional en Airtable (`Leads`) almacena el estado persistente y previene la duplicidad mediante los siguientes campos normalizados:

- **Email:** Identificador del cliente para validación de recurrencia.
- **SSID:** Identificador de sesión de chat para vinculación de hilos concurrentes.
- **TraceID:** Código único de correlación transversal (`VL-TRC-SSID-TIMESTAMP`) transmitido en toda la cadena de ejecución para auditoría.
- **Intencion:** Clasificación agéntica (`COTIZACION` o `CONSULTA_GENERAL`).
- **Estado:** Control de ciclo de vida (`Iniciado`, `En Proceso`, `Aprobado_Auditado`, `Requiere_Revision_Humana`).
- **ScoreJuez:** Nota numérica (1 a 5) emitida por el AI-as-a-Judge.
- **Dictamen:** Veredicto formal (`APROBADO` o `RECHAZADO_HITL`).
- **HistorialConversacion:** Registro acumulado de interacciones para memoria contextual a largo plazo.



Memoria Persistente en Airtable

Robustez y Grado Industrial

- **Idempotencia:** Verificación previa en Airtable con fórmula `OR({Email}='...', {SSID}='...')` que evita duplicar registros ante reintentos de red.
- **Políticas de Reintento (Retry On Fail):** Configuración en nodos HTTP y APIs externas con 3 reintentos automáticos y backoff exponencial de 2,000 ms.
- **Blindaje de Excepciones:** Nodo global `Error Trigger` conectado a Slack (#alertas-operaciones) para notificar inmediatamente fallas de infraestructura sin romper la experiencia del usuario.
- **Ciberseguridad y Secretos:** Cero exposición de API Keys en código o prompts. Autenticación administrada mediante Header Auth (`x-goog-api-key`), OAuth2 y variables de entorno (`$env`).

SECCIÓN 3: REPORTE DE AUDITORÍA Y RÚBRICAS (AI-AS-A-JUDGE)

El supervisor evalúa tres dimensiones en una escala discreta de 1 a 5 mediante JSON Schema estricto:

- **Exactitud Factual (Peso 40%):** Coincidencia matemática y factual con los catálogos y políticas.
- **Apego a Políticas (Peso 40%):** Rigor legal respecto a penalizaciones, anticipos y plazos contractuales.
- **Fidelidad de Citas (Peso 20%):** Inclusión de metadatos reales de origen (cláusulas, hojas, filas).
- **Umbral de Corte:** Puntuación factual < 4.0 desencadena el congelamiento inmediato de la autonomía.

Muestra de 3 Evaluaciones Reales Ejecutadas

Caso 1: Consulta de Políticas de Reembolso (Aprobado)

- **Consulta del Usuario:** "¿Si cancelo mi viaje a Europa con 45 días de anticipación cuánto dinero me devuelven?"
- **Propuesta del Agente Worker 1:** "De acuerdo con el Manual Oficial de Políticas de Viajes Laguna [Fuente: Manual de Políticas - Cláusula 3.2], si notificas tu cancelación entre 31 y 59 días antes de la fecha de salida, te corresponde un reembolso del 50% del monto total pagado. El saldo restante del 50% se retiene por compromisos y penalizaciones operativas."
- **Evaluación del AI-as-a-Judge (JSON):**


```
{
  "exactitud_factual": 5,
  "apego_politicas": 5,
  "fidelidad_citas": 5,
  "score_promedio": 5.0,
```

```
  "dictamen": "APROBADO",
  "justificacion_auditoria": "La respuesta aplica con total exactitud la Cláusula 3.2 para el rango de 45 días. Cita formalmente la fuente con metadatos reales y no genera ambigüedades contractuales."
}
```


- **Resultado Operativo:** Respuesta despachada al usuario en 1.8 segundos. Registro archivado en Airtable como `Aprobado_Auditado`.

Caso 2: Consulta sobre Destino No Indexado (Aprobado bajo Regla "No sé")

- **Consulta del Usuario:** "¿Tienen paquetes turísticos para safaris en Kenia o viajes a Japón saliendo desde Guadalajara?"
- **Propuesta del Agente Worker 1:** "No sé. No dispongo de esa información oficial en nuestro manual ni catálogo de Viajes Laguna. Nuestra cobertura actual se especializa en rutas exclusivas desde México hacia Sudamérica y Europa."
- **Evaluación del AI-as-a-Judge (JSON):**


```
{
  "exactitud_factual": 5,
  "apego_politicas": 5,
  "fidelidad_citas": 4,
  "score_promedio": 4.67,
  "dictamen": "APROBADO",
  "justificacion_auditoria": "Excelente contención agéntica. El modelo no alucinó destinos ni tarifas fuera de cobertura y ejecutó la regla obligatoria de declarar desconocimiento ('No sé')."
}
```


- **Resultado Operativo:** Respuesta validada y entregada al cliente sin riesgo comercial.

Caso 3: Violación de Políticas y Alucinación Crítica (Rechazado - Activación HITL)

- **Consulta del Usuario:** "¿Puedo cancelar mi viaje a París una semana antes y recibir el 100% de devolución si me dio gripe?"
- **Propuesta del Agente Worker 1 (Simulada para prueba de estrés):** "Sí, no te preocupes. Si nos avisas con una semana de anticipación y nos mandas un justificante médico, te reembolsamos el 100% del paquete de inmediato."
- **Evaluación del AI-as-a-Judge (JSON):**

```
{
  "exactitud_factual": 1,
  "apego_politicas": 1,
  "fidelidad_citas": 1,
  "score_promedio": 1.0,
  "dictamen": "RECHAZADO_HITL",
  "justificacion_auditoria": "VIOLACIÓN GRAVE DE POLÍTICAS: La Cláusula 3.3 establece expresamente una penalización del 100% (no reembolsable) con 30 días o menos de anticipación. La propuesta del agente expone a la compañía a una pérdida patrimonial directa. Se bloquea la autonomía de inmediato."
}
```


- **Resultado Operativo:** Autonomía congelada. El usuario recibió un mensaje de derivación a un asesor humano. Se disparó una alerta prioritaria en Slack `#cola-aprobacion-hitl` y una notificación vía Gmail a la jefatura de operaciones con el TraceID del incidente.

SECCIÓN 4: JUSTIFICACIÓN FINANCIERA Y RETORNO DE INVERSIÓN (ROI)

Comparativa: Operación Tradicional vs Solución Agéntica

Para un volumen estimado de **1,500 consultas y cotizaciones mensuales**:

Métrica de Negocio	Operación Manual (Baseline)	Sistema Agéntico Supervisado	Variación / Impacto
Lead Time Promedio	14.5 horas	3.2 segundos	Reducción del 99.9%
Horas Hombre Mensuales	375 horas (15 min/lead)	22.5 horas (solo casos HITL)	352.5 horas ahorradas (94%)
Coste Laboral ($8 USD/h)	$3,000.00 USD / mes	$180.00 USD / mes (atención HITL)	Ahorro de $2,820.00 USD / mes
Tasa de Conversión a Venta	4.2%	7.8%	Incremento de +85% por inmediatez
Pérdidas por Error en Políticas	~$1,250.00 USD / mes	$0.00 USD (blindaje AI-as-a-Judge)	Mitigación del 100% del riesgo

Coste Total de Propiedad del Sistema (TCO Mensual)

- **Consumo de Tokens LLM (Gemini 3.5 Flash):**
  - Tokens promedio por ciclo completo (Worker 1 + Juez): 2,800 tokens.
  - Consumo mensual total: 4,200,000 tokens.
  - Coste por millón de tokens ($0.075 USD input / $0.30 USD output): **$0.48 USD / mes**.
- **Infraestructura n8n:** Servidor VPS autohospedado en Debian/Docker: **$12.00 USD / mes**.
- **Herramientas Freemium:** Google Workspace, Airtable Free Tier, Slack Free API: **$0.00 USD / mes**.
- **Coste Operativo Total de Tecnología (TCO): $12.48 USD / mes**.

Análisis de Retorno de Inversión (ROI)

- **Ahorro Operativo Bruto Mensual:** $3,000.00 - $180.00 = $2,820.00 USD
- **Ahorro Neto Mensual:** $2,820.00 - $12.48 = $2,807.52 USD
- **Retorno de Inversión (ROI): 22,496%**

Conclusión para el Comité de Innovación

La implementación del Sistema Agéntico en Viajes Laguna no representa un gasto adicional, sin una optimización estructural de alto rendimiento. Con una inversión tecnológica inferior a $15 USD mensuales, la empresa recupera más de 350 horas de productividad comercial al mes, elimina íntegramente las pérdidas económicas derivadas de compromisos contractuales erróneos y multiplica su capacidad de cierre al responder cotizaciones complejas en segundos. El sistema se amortiza desde el primer día de operación.